Matrike

A. Blejec

7. maj 2013

Podatki

Podaki so o študentih 3. letnika biologije v letu 2012/13 so v datoteki lfn in na http://bit.ly/16oBVpR

```
fpath <- file.path("../data", lfn)
data <- read.table(fpath, header = TRUE, sep = "\t")
names(data)

[1] "starost" "mesec" "spol" "masa" "visina"
[7] "cevelj" "lasje" "oci" "mati" "oce"</pre>
```

Popravljanje podatkov

Odstranimo ta starga

```
data <- data[data$starost < 30, ]
Podatke o mesecu 0 spremenimo v NA</pre>
```

```
data[data$mesec == 0, "mesec"] <- NA
table(data$mesec)

1  2  3  4  5  6  7  8  9 10 11
1  3  2  3  4  3  7  5  2  5  6</pre>
```

Sprememba podatkov o velikosti majice

```
table (data$majica)
L M S XL XS
4 19 16 1 2
data$majica[data$majica == "XL"] <- "L"</pre>
data$majica[data$majica == "XS"] <- "S"</pre>
 data$majica <- ordered(data$majica, levels = c("S",
      "M", "L"))
 str(data$majica)
Ord.factor w/ 3 levels "S"<"M"<"L": 1 1 1 2 3 1 1 2 2 3
 table(data$majica)
S M L
18 19 5
```

Vektorji

Vektor pripravimo kot *n*-terico s pomočjo funkcije c:

$$x \leftarrow c(1, 2, -1)$$

 $y \leftarrow c(2, 1, 6)$
 x
[1] 1 2 -1
 y
[1] 2 1 6
Vektor ima dolžino:

```
length(x)
[1] 3
```

Vektorska aritmetika

Z vektorji lahko računamo po komponentah:

```
2 * x
[1] 2 4 -2
x + y
[1] 3 3 5
x - y
[1] -1 1 -7
x * y
[1] 2 2 -6
x/y
[1] 0.5000000 2.0000000 -0.1666667
x^y
```

Za ročni vnos in urejanje matrik lahko uporabimo urejevalec tabel edit.

```
if (interactive()) {
      X0 <- make.matrix(n = 5, m = 2)
      X0
      Y
}</pre>
```

Množenje %*% in transpozicija t()

[2.1 -1 -2]

```
(B \leftarrow cbind(x, y))
    х у
[1,] 1 2
[2,] 2 1
[3,] -1 6
(A \leftarrow matrix(c(1, 2, -1, 0), 2, 2))
 [,1] [,2]
[1,] 1 -1
[2,] 2 0
(C \leftarrow (B \% * \% A))
    [,1] [,2]
[1,] 5 -1
[2,] 4 -2
[3,] 11 1
t (C)
    [,1] [,2] [,3]
[1,] 5 4
```

```
X0 \leftarrow cbind(x, y)
 X0
      х у
[1,] 1 2
[2,] 2 1
[3,]-16
 X \leftarrow X0
 dim(X)
[1] 3 2
 n \leftarrow dim(X)[1]
 dimnames (X)
[[1]]
NULL
[[2]]
[1] "x" "y"
```

Povprečja

```
M \leftarrow apply(X0, 2, mean)
 Μ
0.6666667 3.0000000
matrika povprečij
 t(t(rep(1, n))) %*% t(M)
              х у
[1,] 0.6666667 3
[2,] 0.6666667 3
[3,] 0.6666667 3
```

vsredinjena matrika podatkov

0.6666667 3.0000000

```
X \leftarrow scale(X, scale = F)
 X
[1,1 \quad 0.33333333 - 1]
[2, ] 1.3333333 -2
[3, ] -1.6666667 3
attr(, "scaled:center")
0.6666667 3.0000000
vektor povprečij izvlečemo s funkcijo attr
 attr(X, "scaled:center")
```

Matrika SSP

```
C <- t(X) %*% X
C

x y
x 4.666667 -8
y -8.000000 14
```

Kovariančna matrika

```
S \leftarrow C/(n-1)
 S
x 2.333333 -4
y - 4.000000 7
 cov(X)
x 2.333333 -4
y - 4.000000 7
 diag(S)
       x
2.333333 7.000000
```

Matrika varianc

Korelacijska matrika

```
R <- SD1 %*% S %*% SD1
R
[,1] [,2]
[1,] 1.0000000 -0.9897433
[2,] -0.9897433 1.0000000
```

Še enkrat

```
SX <- scale(X)

t(SX) %** SX/(n - 1)

x y

x 1.0000000 -0.9897433

y -0.9897433 1.0000000

cor(X)

x y

x 1.0000000 -0.9897433

y -0.9897433 1.0000000
```

Centroidi na več načinov

```
(X \leftarrow cbind(x, y))
[1,] 1 2
[2,] 2 1
[3,] -1 6
 (colMeans(X))
0.6666667 3.0000000
 (attr(scale(X), "scaled:center"))
0.6666667 3.0000000
 (apply(X, 2, mean))
0.6666667 3.0000000
```

Standardni odkloni

Standardne odklone bi lahko izvlekli kot koren diagonal kovariančne matrike, kot atribut scale ali pa z apply:

Funkcije za linearno algebro

Na voljo imamo funkcije, za manipulacijo matrik in pomembne operacije nad matrikami

- ▶ t() transponiranje matrik
- eigen() lastne vrednosti
- solve() inverzna matrika
- det() determinanta matrike
- sled izračunamo kot vsoto diagonalnih elementov

Lastni vektorji

```
S \leftarrow matrix(c(10, 3, 3, 2), 2, 2)
S
     [,1] [,2]
[1,] 10 3
[2,] 3
eigen(S)
$values
[1] 11 1
$vectors
                     [,2]
           [,1]
[1,] -0.9486833 0.3162278
[2,] -0.3162278 -0.9486833
det (S)
[1] 11
```

Inverzna matrika

```
S1 <- solve(S)

S %*% S1

[,1] [,2]

[1,] 1.000000e+00 0

[2,] -2.220446e-16 1
```

Takole se znebimo zelo majhnih vrednosti v izpisu

Sled bi lahko izračunali kot

```
sum(diag(S))
11 12
```

- ► Iz podatkov data izberite nekaj (3 ali 4) številske spremenljivke in formirajte matriko X
- Narišite pare razsevnih diagramov funkcija pairs()
- Poiščite povprečne vrednosti spremenljivk
- Izračunajte kovariančno in korelacijsko matriko

Podatki

```
X <- data[, c("masa", "visina", "mesec", "roke",</pre>
     "cevelj")]
head(X)
 masa visina mesec roke cevelj
2
   60
        173
               1
                  176
                         43
3
 55
        178
               7 178
                         39
4
 70 167
               8 165
                         39
5 65 171
               4 168 40
6 88 171
              3 173 41
   52
        162
               7 164
                         39
tail(X)
  masa visina mesec roke cevelj
38
    73
               10
                  180
                          42
         173
  58
39
         170
               10
                  171
                          48
40
    56
       158 7 156
                          37
41
  55
       157 4 NA
                       37
42
    50
       160
               10
                  160
                          37
                   187
43
    73
         181
               NA
                          43
                              4□ ト ← □ ト ← 亘 ト → 亘 り へ ○
```

```
cor(X, use = "complete.obs")
```

```
        masa
        visina
        mesec
        roke
        ceve

        masa
        1.00000000
        0.6786316
        0.03182096
        0.6657479
        0.54749

        visina
        0.67863160
        1.00000000
        0.17764477
        0.9393966
        0.69042

        mesec
        0.03182096
        0.1776448
        1.00000000
        0.1609260
        0.10377

        roke
        0.66574793
        0.9393966
        0.16092600
        1.0000000
        0.722581

        cevelj
        0.54749044
        0.6904270
        0.10377266
        0.7225814
        1.00000
```

Test hipotez

Ali so fantje večji od deklet

Funkcija za Student t-test

```
Ali so fantje večji od deklet

student <- function(x, y) {
+ }
```

Permutacijski test

$$H_0: \mu_1 = \mu_2 (= \mu)$$

Če imamo opravka z vzorcema iz iste populacije, potem je lahgko v vsakem vzorcu katerakoli od izmerjenih n_1+n_2 vrednosti. Če imam npr. 10

```
n
[1] 10
sample(10, 4)
[1] 9 8 10 2
```

lahko takole določim, katere vrednosti spadajo v prvi vzorec.

Podatki

Zgenerirajmo podatke iz populacije s povprečjem 10

```
set . seed (555)
n1 < -5
mu1 <- 10
sd1 <- 1
n2 < -5
mu2 < -10
sd2 <- 1
n < -n1 + n2
X1 <- round(rnorm(n1, mu1, sd1), 1)</pre>
X2 \leftarrow round(rnorm(n2, mu2, sd2), 1)
X1
[1] 9.7 10.5 10.4 11.9 8.2
X2
[1] 10.9 9.8 11.4 10.0 10.6
X \leftarrow c(X1, X2)
ind \leftarrow c(rep(1, n1), rep(2, n2))
```

Funkcija za razliko povprečij

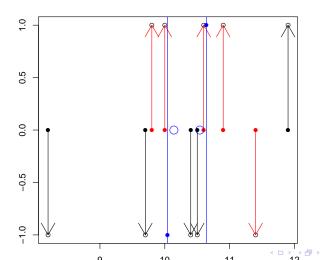
```
dx <- function(x, y) mean(y) - mean(x)
dx(X1, X2)
[1] 0.4</pre>
```

Premešajmo podatke

```
set.seed(432)
  (smp1 <- sample(n, n1))
[1] 3 1 8 2 5
  (smp2 <- (1:n)[-smp1])
[1] 4 6 7 9 10</pre>
```

Premestitev vrednosti

[1] 0.6



Kako je narisano

```
plot(X, rep(0, n), col = ind, pch = 16, ylab = "")
points (X[smp1], rep(-1, n1))
points (X[smp2], rep(1, n2))
arrows(X[smp1], rep(0, n1), X[smp1], rep(-1, n1),
+ col = ind[smp1])
arrows(X[smp2], rep(0, n2), X[smp2], rep(1, n2),
+ col = ind[smp2])
abline(v = mean(X[smp1]), col = 4)
abline(v = mean(X[smp2]), col = 4)
points (c (mean(X[smp1]), mean(X[smp2])), c(-1, 1),
+ pch = 16, col = 4)
points(c(mean(X1), mean(X2)), c(0, 0), col = 4, cex = 2)
dx(X[smp1], X[smp2])
[1] 0.6
```

Funkcija

```
perm.test <- function(x, X1, X2) {
      n1 \leftarrow length(X1)
+
      n2 \leftarrow length(X2)
+
+
      ind \leftarrow c(rep(1, n1), rep(2, n2))
      (smp1 \leftarrow sample(n, n1))
+
      (smp2 <- (1:n)[-smp1])
+
      plot(X, rep(0, n), col = ind, pch = 16, ylab = "")
+
      points(X[smp1], rep(-1, n1))
+
+
      points(X[smp2], rep(1, n2))
      arrows(X[smp1], rep(0, n1), X[smp1], rep(-1,
+
+
          n1), col = ind[smp1]
+
      arrows(X[smp2], rep(0, n2), X[smp2], rep(1, n2),
+
          col = ind[smp2])
+
      abline(v = mean(X[smp1]), col = 4)
+
      abline(v = mean(X[smp2]), col = 4)
+
      points(c(mean(X[smp1]), mean(X[smp2])), c(-1,
          1), pch = 16, col = 4)
+
      points(c(mean(X1), mean(X2)), c(0, 0), col = 4,
+
          cex = 2
+
                                     ◆□▶ ◆□▶ ◆□▶ ◆□▶ □ ◆○○○
```

```
perm.test(x, X1, X2)
[1] 0.68
sapply(1:8, FUN = perm.test, X1 = X1, X2 = X2)
[1] 0.88 0.08 0.04 1.24 0.16 0.12 0.16 -0.04
dx(X1, X2)
[1] 0.4
```